

MANGAL データファイルの素性と名称 ―― 取得物 / 制作物(簡略版)

作成: 2026-06-15 / 目的: いま&今後使うデータを「外から取る物=取得物」と「我々が作る物=制作物」に二分し、名称・素性・取得元・頻度を一枚で把握する。※細かな補正seedは束ねて簡略化。

0. 一行で

取得物(外部から取る素材)を、制作物(我々が組み上げる物)が食べて、最終的に 本番DB(data/manga.v2)→ 索引 → 配信(out/・R2) になる。取得物の更新頻度は 毎蒸留 / 凍結(再取得不要) / 随時 / 将来 の4段。

1. 取得物(外部から取る素材)


名称(素性)	何が入っているか	取得元	頻度
種1: MADB巻データ (cm101 / metadata101)	単行本の書誌=ISBN・巻番号・発売日・出版社・タイトル	MADB(GitHub全件JSON or 公式サイト月次CSV)	毎蒸留(新刊)
MADB著者(cm504)	著者マスター・読み・NDL典拠ID	MADB	毎蒸留
MADBシリーズ/雑誌master (cm104 / cm105 / cm103)	シリーズ束ね・著者役割([原作]/[作画])・雑誌	MADB	凍結(2024-11で更新停止=再取得不要)
漫画家マスター (data/seed/mangaka.csv)	漫画家 約6,751名(別input)	手元CSV	ほぼ固定
AniList	英あらすじ・ジャンル・タグ・別名・人気/評価・staff(著者)・anilist_id	AniList API	毎蒸留(新作Enrich)
楽天ブックス	表紙・価格・発売日(日精度)・アフィリエイトURL	楽天 Books API(1req/秒)	毎蒸留(新ISBN)
Wikidata / Wikipedia	作品QID・著者QID・ジャンルカテゴリ・記事URL	WDQS / QLever / API	随時(品質・enrich時)
NDL(国立国会図書館)	タイトル読み(ふりがな正)・著者典拠・巻構造	NDL SRU	随時(品質監査時)
成年判定リスト	成年作家/出版社/雑誌	adultcomic.dbsearch.net等	随時
Amazon PA-API	表紙・ASIN(楽天に無い旧巻の補完)	Amazon	将来(売上ゲート達成後)

※OpenBD はサービス終了のため不使用。書影の本命は楽天(無料)→将来Amazon。

2. 制作物(我々が作る物)と、食べている取得物

名称(素性)	何	元になる取得物	再生成/更新頻度
種2: 派生DB (.cache/db.sqlite, db-v2.sqlite)	種1を正規化したSQLite(seri es/volumes/mangaka)	種1(MADB)	毎蒸留(取込時)。 .cach e=再生成可
種3: series-supplement.yml	作品単位のAI補完の蓄積	AI(AniList素材)	毎蒸留(純粹追加only)
種4: volumes-supplement.yml	MADB取りこぼし巻の手補完	手(Amazon/NDL/公式で確 認)	随時(手動add)
synopsis-ja.json	AI日本語あらすじ要約(anilis t_id key)=高価なAI生成物	AniList英descをAI要約	毎蒸留(純粹追加)
catch-ja.json	キャッチコピー(slug key)	AI生成(あらすじ素材)	随時/蒸留
release-date-fill.json	発売日の日精度補完(isbn key)	楽天	毎蒸留
品質補正seed群 (furigana-corrections / author-yomi / author-role-corrections / slug-aliases / non-manga-drop / page-dedup / series-merge 等)	ふりがな・著者読み・役割・ slug別名・除外・重複統合な どの補正蓄積	NDL / 手 / AI	随時(純粹追加)
master(設定) (genres / publishers / magazines / demographics .yml)	語彙・キー定義(裁定マター)	手(ユーザ裁定)	随時(新キーflag時)
★本番DB: data/manga.v2	全部を焼き込んだ公開出力(約66,582作・gitignore)	promote=種2+種3+種4+s eed+取得をjoin	毎蒸留(全再生成)
索引(A SQLite + S1/S2/S3)	検索/監査/配信用の索引(別 仕様書)	data/manga.v2	promote毎(再生成可)
配信: out/ + R2バケット	静的サイト本体(HTML/JS/ 索引)	data/manga.v2 + 索引	デブロイ毎

3. 系譜(取得 → 制作 → 配信)の一望



4. 「どこから・どの頻度で取るべきか」まとめ

- 毎蒸留(必須): MADB(cm101巻+cm504著者)/ AniList(enrich)/ 楽天(表紙・価格・日付)。→
これらが新刊と補完の源。cm104凍結で著者役割が新作に無い分も AniList で恒久補完。
- 凍結(再取得不要): MADB cm104/cm105/cm103(2024-11停止)。シリーズ束ね・雑誌・役割マスターは固定。
- 随時: NDL(ふりがな/巻構造の裏取り)/ Wikidata(QID・ジャンル)/ 成年リスト。品質監査・特定課題のとき。
- 将来: Amazon PA-API(楽天に無い旧巻表紙)。売上ゲート達成後。

5. 運用原則(素性の扱い)

- 再生成できる物は git に焼かない: 種2DB・索引・out/ は .cache/出力(レシピ=スクリプトだけ追跡)。
- 高価なAI生成物だけ seed 化: synopsis-ja.json / catch-ja.json / 種3 は作り直しが高いため git 永続化。
- 取得物は dedup 前提: MADB-IDで upsert + ISBN/巻番号で重複除去(経路が重なっても安全)。
- 純粹追加 only(種1/2/3): 既存の上書き/削除は禁止=蒸留の大原則。

要約: 取得物=MADB/AniList/楽天/NDL/Wikidata/成年/(将来Amazon)。制作物=種2DB・種3/4・各seed・master・本番manga.v2
・索引・配信。毎蒸留で動く取得物は MADB・AniList・楽天 の3本。