

月次蒸留 計画書(全文)

MANGAL データ更新の標準手順。トリガー語「月次蒸留して」(完全一致)でこの手順を厳密実行する。本書は CLAUDE.md の protocol を一冊に整形したもの。

0. 大原則(絶対遵守)

種1 / 種2 / 種3 は壊さない。差分は純粋追加 only。既存への上書き・削除・編集は禁止。上書き/削除/既存破壊を一件でも検出した時点で即 abort + ユーザ通知。
種1=MADB raw / 種2=派生DB(sqlite)/ 種3=AI fill蓄積 / 種4=巻補完。系譜は別紙(データ素性PDF)。

1. Phase 0 —— 前提確認(1つでも欠ければ即 abort)

以下が無い場合「対象Xが無いので蒸留できない」と報告して終了。自動 fallback / 自動作成はしない。

必要なもの	素性
.cache/madb-last-release.txt	前回取込んだ MADB release tag
.cache/db.sqlite	種2=派生DB
data/seeds/series-supplement.yml	種3=AI fill蓄積
種1 raw(cm101.csv / metadata101.json)	MADB release zip 由来(.cache配下に unzip 想定)
data/seed/mangaka.csv	漫画家マスター(約6,751名・種1とは別input)
scripts/_diff-madb.ts / _diff-series.ts / _select-supplement-diff.ts	種1差分 / 種2差分 / 種3 fill候補生成
git status = clean	dirty なら abort

2. Phase 1 —— 差分レポート + Go サイン待ち

- MADB latest release を GitHub API で取得(確定 repo)。
- 前回取込 tag と比較し、各層の差分件数を表示: 種1=新ISBN N件/新mangaka推定・種2=新series M件(4層 adult filter後)・種3=未fill K件。
- AI fill 予想コスト: K/100 batch、Jセッション分、概算金額。
- 削除予測=0件を明示(0でなければ Phase2 に進まず別途協議)。
- 「進めて OK?」でユーザ確認。Goサイン(「OK」「進めて」「ゴー」等の明示的肯定)受領まで Phase2 に進まない。

3. Phase 2 —— Go サイン後の実行(順序厳守)

- 種1 取込: cm101.csv 取得 → 新ISBNのみ追記、既存行は不変。
- 種2 差分反映: fetch-madb incremental、INSERT only(削除禁止)。
- 派生層+matcher+本番 再生成 = python scripts/intake.py --run。内訳: roles→merge→seed4→detect → matcher v9→v13→v14 → adult_us map → trailing → foreigndrop(外国版自動drop)→ promote(adult_us付与)。※matcherは約20分。終了後 git diff で本番yml確認→commit/push。
- 種a productionization の種3書込(match-v14確定後): en-fill=AniList英題を alternative_titles.en に純粋追加(.new検証→置換)。将来: anilist_id 結線も同手法で純粋追加。
- 種3 diff 元生成: select-supplement-diff で未fill key list 出力。
- AI fill batch loop: dict形式JSON・100entry/batch・_apply-fills 適用。PUA文字混入時は Python経由で生キー書出。JST時刻付き block単位報告。commit+push。
- 最終 summary: 全件数 + 削除0確認 + 次月予測。

4. 保護策(5層)

- 1 取込前に .cache/db.sqlite を db.sqlite.bak-YYYYMMDD-HHMMSS に backup。
- 2 種1/種2/種3 の各取込は単独 commit で分離(後 revert 可)。
- 3 各 batch 後に applied=N, missing=0, overwrites=0 を強制 log 出力。
- 4 tsc / vitest が以前緑なのに赤転落で abort。
- 5 想定外 delete / overwrite 検出で abort。

5. Abort 条件(検出したら即停止+通知)

- 種1 既存行が変更された(MADBが過去ISBNを訂正したケース)。
- 種2 series数が減った(削除発生=異常)。
- 種3 既存 key の content が変わった(上書き=異常)。
- typecheck / test の green→red 転落。

6. 報告形式

- 100 batch ごと: 「□ Batch NNN/MMM 完了 (= X/Y = Z%) [JST YYYY-MM-DD HH:MM:SS]」。
- 完了時: 累計件数 + 残件数 + 次月予測。

7. データ実態と運用補強(必読)

MADB データ入手=2経路

- GitHub 全件JSON(github.com/mediaarts-db/dataset)= その日までの全件snapshot(baseline)。重いが madbdata:dateModified を持つ=変更検知に使える。
- MADBサイト 月次CSV(s-db.artmuseums.go.jp)= 項目×月単位(登録日基準の差分)。軽い・新鮮・未来の発売前予約も載る。ただし更新日列が無い=修正に気付けない(列52・複数著者は \\ 区切り)。
- 運用: GitHub全件を定期 re-sync して訂正回収 + 月次サイト差分で新刊 top-up。

master 凍結の実態

- cm104(シリーズmaster)/ cm105(雑誌)/ cm103 は 2024-11-25 で凍結。最新リリースでも同じ=再DL無駄。更新は cm101(巻)+ cm504(著者)のみ。
- 帰結: 新刊は「マンガ単行本シリーズ」□ 0%=シリーズ層は空。著者役割([原作]/[漫画])は cm104 にしか無く、新作は AniList 補完が恒久策(gapは毎月増える)。

取込の必須2策

- 重複: MADB-ID で upsert + ISBN/巻番号で dedup(冪等・経路が重なっても安全)。危険型=「別MADB-ID+別ISBNでの再登録」(虚構推理vol23型)→ 監査で検知。
- 変更検知: 月次CSVは更新日列が無く修正を見逃す → GitHub全件の dateModified を定期比較して訂正回収。

enrich=毎月の必須ステップ(masterが埋めないため)

- AniList 照合 → 著者補完(原作/作画分離)/ synopsis和訳 / 作品QID / 種4 trailing補完。
- 凍結で新作 gap が累積 → 毎蒸留で再フェッチ(一度きりでない)。

8. synopsis 和訳 = git追跡 seed(永続化の正規ルート)

- 何: AniList英descを AIが60-120字の日本語要約に(逐語訳でなく要約=著作権配慮)。key=anilist_id(作品単位)。
- どこ: data/seeds/synopsis-ja.json(git追跡seed・{anilist_id:ja}の単純map)。
- なぜseed化: synopsisだけが「高価なAI生成物」。他のenrich(synonyms/genres/tags/anilist_id/QID)はdump+match から毎promoteタダで再joinできるので git に焼かない(再生成可能なものは永続化しない原則)。種3本体にも焼かない。

蒸留での扱い(純粹追加only)

- 1 enrich(match-v14)で新規 anilist_id が増える → _build-anilist-enrich-map.py。
- 2 未訳delta抽出: enrichのaidのうち synopsis-ja.json に未存在 かつ AniList desc有 を todo化(100件/batch)。
- 3 分散workflowで各batchをAI要約 → 書出(中断耐性)。
- 4 全出力を merge → _apply-synopsis.py で synopsis-ja.json へ純粹追加(新規N/上書き0を確認)。
- 5 commit + push(git永続化=別PC・モバイルでも消えない)。
- 6 本番反映は全DB promote 時に manga.v2 へ焼かれて確定(seed commitだけでは本番に出ない)。

成人(isAdult): 露骨な性描写は要約に含めない/中立化。表示は adult_us/geo で出し分け。

9. 月次サニティ 監査(silent例外の安全網)

取込後に前月差分で異常を機械flagする。個別例外を全部予見できない前提の最後の砦。

監査層	ツール / 内容
土台(被覆・品質)	_coverage-audit.py=真の公開数・被覆・品質flag。前月差分で『今月だけ急増した異常』を浮かす
巻番号	_audit-volume-numbering.py=AUTO_FIXED(下=3型水増し是正済・件数監視)/MISSING_HALF(片側欠落=種4領域)/ GAP_OTHER(真の欠番・外れ値)
フリガナ	_furigana-audit.py=NDL公式読みをground-truthに誤フリガナ検出
外国版	_audit-foreign-editions.py=複数証拠(latin題/全ISBN非9784/複数巻)でscope外を検出→foreigndropで純粹追加drop
出版社	各版の出版社は ISBN→metadata101 schema:publisher から自動導出。新規の未キー社名を巻数順にflag→主要なら publishers.yml にキー追加

既知の例外型: 再登録の別ID二重化 / MADB形式変更(タグ消失・年→巻番号)/ 成年誤flag(新レーベル未カバー)/ 雑誌漏れ(cm105凍結)/ 巻番号水増し(下=3型)/ 外国版流入(ISBN国コード非9784)。

10. 種4(MADB取りこぼし巻 補完)の扱い

- 種4 = data/seeds/volumes-supplement.yml。公式販売されているが MADB record に無い巻を、別source(Amazon/NDL/出版社公式)で確認後に登録。種2 sqlite は不変。
- 月次蒸留では触らない(手動add only)。audit + 本番yaml生成時に load される。
- render時ガード: 同番号が種2に在れば種4を skip(MADB追いつき時の二重表示防止)。
- 退役 hygiene: MADBが追いついた種4 entry を月次で除去=lean維持。

以上が月次蒸留の全手順。トリガーは「月次蒸留して」。Phase0→1(Goサイン)→2を順序厳守、純粹追加only、異常検出で即abort。